

LAPORAN AKHIR
PROYEK PENGGANTI UAS

Mata Kuliah Kecerdasan Buatan
Semester Genap 2025/2026

**PREDIKSI WAKTU TEMPUH JANGKA PANJANG PADA
DATASET TAIWAN FREEWAY MENGGUNAKAN
ARSITEKTUR LONG SHORT-TERM MEMORY (LSTM)**

Evaluasi Komparatif terhadap Baseline Non-Sekuensial dan Analisis Variabilitas Performa pada
Kondisi Temporal Jam Sibuk versus Non-Sibuk

Disusun oleh:

Grace Yunike M. S NPM 2306267031

Isyana Trevia Pohaci NPM 2306250592

Stevie Nathania Siregar NPM 2306242382

Wiellona Darlene O. S NPM 2306264396

Dosen Pengampu:

Muhammad Firdaus Syawaludin Lubis,
S.T., M.T., Ph.D., CertDA

DEPARTEMEN TEKNIK KOMPUTER
FAKULTAS TEKNIK
UNIVERSITAS INDONESIA

MEI 2026

LEMBAR PERNYATAAN ORISINALITAS

Kami yang bertandatangan di bawah ini menyatakan bahwa laporan ini, beserta seluruh isinya (termasuk Sub-bab IV.x masing-masing anggota dan berkas `metadata.json` yang merupakan bagian tidak terpisahkan), adalah hasil karya kelompok kami sendiri. Setiap kutipan, kode, atau gambar yang berasal dari sumber lain telah disitasi dengan benar. Penggunaan AI *assistant* telah dideklarasikan secara jujur pada Sub-bab IV.x.2.

Grace Yunike M. S

NPM. 2306267031

()

Isyana Trevia P.

NPM. 2306250592]

()

Stevie Nathania S

NPM. 2306242382

()

Wiellona Darlene O.

NPM. 2306264396

()

DAFTAR ISI

DAFTAR GAMBAR.....	4
DAFTAR TABEL.....	5
ABSTRAK.....	6
BAB 1.....	7
PENDAHULUAN & DEFINISI MASALAH.....	7
1.1 Topik yang Dipilih.....	7
1.2 Rumusan Masalah.....	7
1.3 Tujuan Proyek.....	7
1.4 Ruang Lingkup & Batasan.....	7
BAB 2 PENDEKATAN AI.....	9
2.1 Tinjauan Pustaka (Related Work).....	9
2.2 Landasan Teori Model yang Dipilih.....	10
2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI.....	12
2.4 Block Diagram Sistem End-to-End.....	14
2.5 Flowchart Program.....	14
BAB 3 IMPLEMENTASI & HASIL EKSPERIMEN.....	15
3.1 Dataset & Pra-pemrosesan.....	15
3.1.1 Deskripsi Dataset.....	15
3.1.2 Pra-pemrosesan Data.....	16
3.2 Konfigurasi Eksperimen.....	18
3.3 Metrik Evaluasi.....	19
3.4 Hasil Kuantitatif.....	21
3.4.1 Pra-pemrosesan Data.....	21
3.4.2 Analisis Hasil.....	21
3.4.3 Analisis Edge Case antara Peak dan Non Peak Hours.....	22
3.5 Analisis Hyperparameter Tuning.....	22
3.6 Hasil Kualitatif & Error Analysis.....	23
3.7 Pembahasan.....	25
BAB 4.....	28
PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL.....	28
4.1 Isyana Trevia Pohaci – NPM. 2306250592.....	28
IV.1.1 Komponen yang Dikerjakan.....	28
IV.1.2 Pernyataan Penggunaan AI Assistant.....	28
4.2 Stevie Nathania Siregar] – NPM. 2306242382.....	28
IV.2.1 Komponen yang Dikerjakan.....	28
IV.2.2 Pernyataan Penggunaan AI Assistant.....	30
4.3 Grace Yunike Margaretha Sitorus – NPM 2306267031.....	30
IV.3.1 Komponen yang Dikerjakan.....	30
IV.3.2 Pernyataan Penggunaan AI Assistant.....	30
4.4 Wiellona Darlene Oderia Saragih – NPM. 2306264396.....	31

IV.3.3 Komponen yang Dikerjakan.....	31
IV.3.4 Pernyataan Penggunaan AI Assistant.....	31
BAB 5.....	32
KESIMPULAN & PEKERJAAN LANJUTAN.....	32
5.1 Kesimpulan.....	32
5.2 Klaim Bonus Skor.....	33
5.3 Pekerjaan Lanjutan (Future Work).....	33
DAFTAR PUSTAKA.....	35
LAMPIRAN A.....	36
Berkas Metadata Proyek (JSON).....	36
LAMPIRAN B.....	37
Tautan Repositori & Dataset.....	37
APPENDIX C.....	38
Individual Consent — Member 1.....	39
Individual Consent — Member 2.....	41
Individual Consent — Member 3.....	43
Individual Consent — Member 4.....	45

DAFTAR GAMBAR

Gambar 3.1 Perbandingan performa model berdasarkan MAE, RMSE, dan visualisasi prediksi vs aktual pada Route 1.	24
Gambar 3.2 Perbandingan MAE pada kondisi peak hour dan non-peak hour untuk setiap route.	24

DAFTAR TABEL

Tabel 2.1: Ringkasan tinjauan pustaka	16
Tabel 3.1: Fitur Utama	16
Tabel 3.2: Karakteristik Rute	17
Tabel 3.3: Strategi Sliding Window	19
Tabel 3.4: Hyperparameter eksperimen	20
Tabel 3.5 Metrik Evaluasi	22
Tabel 3.6 Hasil evaluasi ketiga model	22
Tabel 3.7 Analisis Edge Case antara Peak dan Non Peak Hours	23
Tabel 3.8 Hasil Hyperparameter Tuning Model LSTM	23
Tabel 3.9 Perbandingan MAE pada kondisi peak hour dan non-peak hour	25
	47

ABSTRAK

Prediksi waktu tempuh merupakan salah satu penerapan AI pada data lalu lintas yang bersifat dinamis dan berubah terhadap waktu. Proyek ini menggunakan Long Short-Term Memory (LSTM) berbasis Recurrent Neural Network (RNN) untuk memprediksi waktu tempuh pada *Taiwan Freeway Travel Time Dataset*. Dataset yang digunakan berasal dari sensor lalu lintas jalan tol Taiwan dengan fitur utama berupa waktu tempuh, kecepatan rata-rata, dan volume kendaraan. LSTM dibandingkan dengan Linear Regression dan *XGBoost*, menggunakan metrik evaluasi Mean Absolute Error (MAE), *Root Mean Square Error* (RMSE), dan *R-squared* (R^2). Selain itu, terdapat analisis performa model pada kondisi jam sibuk dan non-sibuk untuk melihat konsistensi model dalam menangkap pola temporal lalu lintas.

Kata kunci: LSTM, Recurrent Neural Network, *time-series*, prediksi waktu tempuh, *traffic prediction*.

BAB 1

PENDAHULUAN & DEFINISI MASALAH

1.1 Topik yang Dipilih

Proyek ini mengimplementasikan topik *Recurrent Neural Network* (RNN) dengan arsitektur *Long Short-Term Memory* (LSTM) untuk memprediksi waktu tempuh pada data deret waktu lalu lintas di Taiwan. Dataset yang digunakan adalah Taiwan Freeway Travel Time Dataset periode Januari-Juli 2018, yang terdiri dari data sensor lalu lintas bersifat *time-series* dengan granularitas temporal yang konsisten. Pemilihan topik ini didasari oleh karakteristik data lalu lintas yang memiliki pola ketergantungan sekuensial kuat (harian, mingguan, dan musiman), dimana model tradisional berbasis statistik atau *tree-ensemble* sering kali gagal menangkap *long-term dependency* secara optimal. Arsitektur LSTM dipilih karena mekanisme *gate*-nya secara eksplisit dirancang untuk mempertahankan informasi temporal jangka panjang dan memitigasi masalah *vanishing gradient*, sehingga secara teoritis lebih sesuai untuk tugas *forecasting* jangka panjang pada data deret waktu.

1.2 Rumusan Masalah

RM1. Apakah arsitektur LSTM mampu menurunkan MAE dan RMSE secara signifikan dibandingkan baseline XGBoost dan Regresi Linier untuk prediksi 1 jam ke depan pada dataset Taiwan Freeway?

RM2. Bagaimana perubahan performa ketika data uji dipisahkan berdasarkan kondisi temporal (jam sibuk vs non-sibuk) dan panjang rute, serta apakah terdapat pola residual yang mengindikasikan bias kontekstual?

RM3. Bagaimana perbandingan kinerja prediksi waktu tempuh antara model sekuensial (LSTM) dengan model non-sekuensial (XGBoost dan Regresi Linier) pada dataset berskala mikro?

1.3 Tujuan Proyek

T1. Menerapkan arsitektur Long Short-Term Memory (LSTM) berbasis Recurrent Neural Network (RNN) untuk memprediksi waktu tempuh pada data lalu lintas time-series menggunakan Taiwan Freeway Travel Time Dataset.

T2. Membandingkan performa model LSTM dengan model *baseline* non-sekuensial, yaitu *Linear Regression* dan *XGBoost*, menggunakan metrik evaluasi MAE, RMSE, dan R^2 .

T3. Menganalisis performa model pada kondisi jam sibuk dan non-sibuk untuk melihat kemampuan model dalam menangkap pola temporal lalu lintas.

1.4 Ruang Lingkup & Batasan

1. **Batasan Dataset (*Micro-scale*):** Mengingat keterbatasan data, proyek ini secara spesifik membatasi ruang lingkup pada analisis pola lalu lintas 1 hari penuh (1 Januari 2018, hari libur Tahun Baru).
2. **Strategi Pemenuhan Sampel:** Untuk menghindari *overfitting*, data dari minimal 3 rute jalan tol (misal: Rute 8 km, 25 km, dan 37 km) digabungkan secara vertikal (*vertical concatenation*) sehingga model dilatih sebagai *multi-route time series*.
3. **Analisis Edge Case:** Kondisi jam sibuk (*peak hour*) didefinisikan berdasarkan lonjakan volume kendaraan pada pagi/sore hari libur tersebut, dibandingkan dengan jam non-sibuk (malam/dini hari).

BAB 2

PENDEKATAN AI

2.1 Tinjauan Pustaka (*Related Work*)

Tabel 2.1: Ringkasan tinjauan pustaka

Penulis (Th.)	Metode	Dataset	Hasil	Keterbatasan
Chuang et al[1]	Interpolasi, max-value, dan metode deep learning untuk missing/zero values	Dataset TTP Taiwan & California	Interpolasi dan max-value terbaik untuk mengisi nilai nol/hilang. Ditemukan bahwa DL-based imputation justru lebih buruk	Hasil dapat bergantung dengan karakteristik data lain
Duan et al[2]	LSTM seri per-link untuk prediksi multi-step travel time	Travel time 66 link, Highways England	Median MRE 1-step $\approx 7\%$ pada 66 link	Model LSTM hanya dibangun satu per ruas dan hanya memanfaatkan informasi deret waktu pada link itu sendiri tanpa pemodelan eksplisit hubungan antar-ruas
Zijing Yang et al[3]	CNN + GRU + multi-task learning + time-separated attention	Dataset Quanzhou & California	Metode CNN + GRU + multi-task learning dengan time-separated attention ini mengungguli DCRNN, 1D-CNN-LSTM, ConvLSTM, Graph WaveNet,	Hanya diuji pada dua dataset tertentu dan tidak memberikan detail beban komputasi dan metrik lainnya.


Penulis (Th.)	Metode	Dataset	Hasil	Keterbatasan
			ST-ResNet; robust pada data ber-noise	

Berbeda dengan penelitian yang terdapat pada table yang fokus pada prediksi per-ruas secara terisolasi [2] atau menggunakan arsitektur hybrid kompleks [3], proyek ini memberikan kontribusi melalui evaluasi komparatif sistematis antara arsitektur sekuensial (LSTM) dengan baseline non-sekuensial (Linear Regression dan XGBoost) untuk prediksi jangka panjang (>1 jam), dilengkapi dengan analisis variabilitas performa pada kondisi temporal jam sibuk versus non-sibuk yang belum dieksplorasi pada studi-studi terdahulu.

2.2 Landasan Teori Model yang Dipilih

Long Short-Term Memory (LSTM) merupakan pengembangan dari arsitektur RNN yang dirancang khusus untuk mengatasi masalah *vanishing gradient* saat mempelajari data sekuensial dengan ketergantungan jangka panjang. Pada konteks time series pada [1], LSTM terbukti andal sebagai model dasar dalam menangkap pola pergerakan temporal yang dinamis, seperti tren jam sibuk dan kondisi lalu lintas yang fluktuatif pada *Taiwan Freeway*.

LSTM terdiri dari memori internal (*cell state*) dan tiga unit gerbang pengendali informasi, yaitu *forget gate*, *input gate*, dan *output gate*.



Gambar 2.1: Arsitektur LSTM (Sumber: [1])

Setiap gerbang menggunakan fungsi aktivasi non-linear untuk menyaring atau menambahkan informasi ke dalam cell state. Secara matematis, operasi pemrosesan informasi di dalam sel LSTM pada suatu langkah waktu (time step) ke- t dirumuskan melalui persamaan-persamaan berikut:

1. Forget Gate (f_t): Menentukan probabilitas informasi historis dari cell state sebelumnya yang akan dibuang atau dipertahankan.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.1)$$

2. Input Gate (i_t) dan Candidate Cell State ($\bar{C}_t$): Input gate menentukan informasi baru mana yang akan diperbarui, sedangkan Cell State menghasilkan vektor kandidat informasi baru yang potensial untuk ditambahkan.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.2)$$

$$\bar{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (2.3)$$

3. Cell State Update (C_t): Menghitung status memori terbaru dengan mengalikan status lama dengan forget gate, dan menambahkan informasi kandidat baru yang telah difilter oleh input gate.

$$C_t = f_t * C_{t-1} + i_t * \bar{C}_t \quad (2.4)$$

4. Output Gate (o_t) dan Hidden State (h_t): Menentukan vektor keluaran (hidden state) untuk langkah waktu saat ini, yang juga akan diteruskan ke langkah waktu berikutnya.

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.5)$$

$$h_t = o_t * \tanh(C_t) \quad (2.6)$$

dengan:

- x_t : vektor input fitur pada waktu ke- t
- h_{t-1}, h_t : Vektor keluaran (hidden state) pada waktu ke-($t-1$) dan ke- t .
- C_{t-1}, C_t : Vektor memori (cell state) pada waktu ke-($t-1$) dan ke- t .
- W_f, W_i, W_c, W_o : Matriks bobot (weight matrices) untuk masing-masing gerbang dan kandidat memori.
- b_f, b_i, b_c, b_o : Vektor bias (bias terms) yang akan dipelajari oleh model.
- σ : Fungsi aktivasi sigmoid yang memetakan nilai ke rentang (0, 1).
- $\tanh$: Fungsi aktivasi tangen hiperbolik yang memetakan nilai ke rentang (-1, 1).

Melalui mekanisme gerbang ini, model LSTM dapat secara selektif mengingat pola jangka panjang yang esensial (seperti pola repetitif mingguan) dan melupakan gangguan acak (*noise* sementara) di sepanjang dataset, sehingga menghasilkan prediksi waktu tempuh yang memiliki akurasi tinggi.

2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI

Pemilihan arsitektur Long Short-Term Memory (LSTM) dengan mekanisme hyperparameter tuning sebagai model utama didasarkan pada pertimbangan ilmiah yang selaras dengan karakteristik data, keterbatasan sumber daya komputasi, dan dinamika domain prediksi lalu lintas. Berikut penjelasan rinci yang mencakup tiga aspek wajib dalam pemilihan pendekatan..

A. Alasan Pemilihan Arsitektur dan Perbandingan dengan Alternatif

Arsitektur LSTM dipilih karena data waktu tempuh bersifat sekuensial dengan ketergantungan temporal yang kuat antar interval waktu. Model alternatif memiliki keterbatasan spesifik pada proyek ini:

- **Transformer** unggul dalam menangkap dependensi jarak sangat jauh, tetapi memerlukan volume data yang sangat besar dan biaya komputasi tinggi. Pada dataset berukuran satu tahun dengan interval lima menit (~105.000 sampel per rute), Transformer cenderung mengalami overfitting atau memerlukan mekanisme regularisasi kompleks yang justru menurunkan efisiensi pelatihan.
- **Convolutional Neural Network (CNN)** berfokus pada ekstraksi fitur lokal dan spasial. Arsitektur ini kurang optimal untuk memodelkan dinamika urutan waktu karena tidak menyimpan state internal antar langkah waktu.
- **Model Non-Sekuensial (Regresi Linier, XGBoost)** memerlukan rekayasa fitur lag manual. Pendekatan ini rentan terhadap kebocoran data, kehilangan informasi urutan, dan gagal menangkap pola dinamis jangka menengah tanpa penyesuaian fitur yang masif.

LSTM secara inherent memproses data berurutan melalui tiga gerbang terstruktur (input, forget, output). Mekanisme ini menjaga memori jangka panjang, mengatasi masalah vanishing gradient pada RNN standar, dan secara otomatis mempelajari pola periodisitas tanpa rekayasa fitur tambahan.

B. Pertimbangan Trade-off (Akurasi vs Kecepatan vs Ukuran Model vs Kebutuhan Data)

Keputusan arsitektur melalui proses evaluasi dan analisis trade-off berikut:

- **Akurasi vs Kecepatan komputasi:** Hasil grid search menunjukkan konfigurasi 2 lapisan LSTM, 64 unit, dropout 0,2, dan learning rate 0,001 menghasilkan MAE terendah (8,25 menit) pada data uji. Penambahan lapisan atau unit hanya meningkatkan waktu pelatihan secara signifikan tanpa perbaikan akurasi yang proporsional.
- **Ukuran model vs Kebutuhan inferensi:** Model akhir memiliki parameter sekitar 200 ribu. Ukuran ini tetap ringan dan mendukung latensi inferensi di bawah 50 milidetik, sehingga sesuai untuk implementasi sistem prediksi lalu lintas real-time pada perangkat dengan sumber daya terbatas.
- **Kebutuhan data vs Generalisasi:** LSTM memiliki efisiensi sampel yang tinggi

dibandingkan arsitektur berbasis attention. Model ini konvergen stabil pada dataset berukuran menengah tanpa memerlukan tahap pre-training skala besar atau augmentasi data yang kompleks.


- **Risiko Overfitting vs Regularisasi:** Penerapan dropout 0,2 dan mekanisme Early Stopping (patience=5) selama pelatihan menjaga bobot model tetap general pada pola temporal yang belum terlihat, sekaligus menghemat waktu pelatihan dengan menghentikan proses pada epoch optimal (rata-rata epoch 10 hingga 12).

C. Konteks Domain yang Membuat Pilihan Ini Superior

Karakteristik fisik dan operasional lalu lintas jalan tol secara alami selaras dengan kapabilitas LSTM:

- **Pola Periodisitas dan Variabilitas Temporal:** Data TDCS menunjukkan fluktuasi harian yang terstruktur antara jam sibuk dan jam sepi. Gerbang forget pada LSTM secara otomatis menyaring informasi yang tidak relevan antar siklus, sedangkan cell state mempertahankan tren kemacetan yang berkembang sepanjang waktu.
- **Propagasi Kemacetan Non-Linear:** Waktu tempuh tidak berubah secara linear terhadap kepadatan lalu lintas. Transisi fase dari arus bebas menuju kemacetan bersifat mendadak dan dinamis. Fungsi aktivasi tanh dan sigmoid pada LSTM memberikan kapasitas pemodelan non-linear yang diperlukan untuk menangkap transisi tersebut tanpa asumsi stasioneritas kaku.
- **Adaptasi terhadap Panjang Rute:** Ketiga rute yang digunakan memiliki jarak berbeda (8 km, 25 km, dan 37 km). Rute panjang cenderung mengalami akumulasi ketidakpastian prediksi. Pendekatan LSTM yang dilatih secara terpisah per rute dengan parameter yang telah di-tune memberikan fleksibilitas untuk menyesuaikan kapasitas memori (lstm_units) dan kekuatan regularisasi (dropout) terhadap kompleksitas spasial masing-masing rute.
- **Ketahanan terhadap Noise Sensor:** Data sensor TDCS mengandung nilai nol yang merepresentasikan sensor offline, bukan kondisi jalan kosong. Kombinasi LSTM dengan metode imputasi temporal (Chou's Method) memberikan ketahanan yang lebih baik dibandingkan model yang mengasumsikan distribusi data sempurna, karena LSTM tetap dapat mengandalkan konteks historis saat input saat ini tidak stabil.

2.4 Block Diagram Sistem End-to-End



Gambar 2.2: Block diagram sistem yang diusulkan

2.5 Flowchart Program



Gambar 2.3: Flowchart program training dan inference

BAB 3

IMPLEMENTASI & HASIL EKSPERIMEN

3.1 Dataset & Pra-pemrosesan

3.1.1 Deskripsi Dataset

Proyek ini menggunakan Taiwan Freewat Travel Time Dataset periode Januari sampai Juli 2018, yang merupakan dataset publik berisi data sensor lalu lintas jalan tol Taiwan dengan granularitas temporal 5 menit. Dataset ini dipilih oleh kelompok kami karena:

- Memiliki pola ketergantungan ketergantungan, yaitu harian dan mingguan yang sesuai dengan arsitektur RNN.
- Menyediakan edge case temporal yang jelas, yaitu antara jam sibuk dan non sibuk untuk dilakukan analisis bias.
- tersedia secara publik dengan dokumentasi lengkap untuk melakukan reproduibilitas.

Fitur utama:

Tabel 3.1: Fitur Utama

Fitur	Deskripsi	Satuan
TravelTime	Waktu tempuh kendaraan antar sensor	menit
AvgSpeed	Kecepatan rata-rata kendaraan	k/jam
TrafficFlow	Volume kendaraan per interval	kendaraan/5-menit
Timestamp	Waktu pencatatan sensor	datetime

Dataset terdiri dari 3 rute dengan karakteristik berbeda:

Tabel 3.2: Karakteristik Rute

Route	Jarak	Jumlah Sampel
from01F0147Sto01F0155S	8 km	105.120
from01F0339Sto01F0376S	37 km	105.120
from01F0532Sto01F0557S	25 km	105.120

3.1.2 Pra-pemrosesan Data

a. Penanganan Missing Value dan Sensor Error

Sensor lalu lintas sering menghasilkan nilai 0 yang bukan merepresentasikan "jalan kosong", melainkan indikasi sensor offline atau error transmisi. Kami menerapkan Chou's Imputation Method (Nature Scientific Reports, 2025) untuk mengisi nilai invalid:

```
def chou_imputation(series, window=3):
    """Mengisi nilai 0/NaN dengan rata-rata tetangga temporal valid"""
    res = series.copy()
    invalid_idx = res[(res == 0) | (res.isna())].index

    for idx in invalid_idx:
        start = max(0, idx - window)
        end = min(len(res), idx + window + 1)
        neighbor = res[start:end]
        valid = neighbor[(neighbor > 0) & (neighbor.notna())]

        if len(valid) > 0:
            res[idx] = valid.mean()
        else:
            # Fallback: gunakan median historis
            res[idx] = series[series > 0].median() if (series > 0).any() else 10.0

    return res
```

Metode ini dipilih karena lebih stabil dibanding interpolasi linear atau forward-fill untuk data deret waktu dengan missing at random pattern.

b. Sequence Windowing untuk LSTM

LSTM memerlukan input 3D, yaitu samples, timesteps, features. Kami menggunakan

strategi sliding window:

Tabel 3.3: Strategi Sliding Window

Parameter	Nilai	Deskripsi
WINDOW_SIZE	24	24 slot $\times$ 5 menit = 2 jam historis sebagai input
HORIZON	12	Prediksi 12 slot ke depan = 1 jam (long-term forecasting)
FEATURES	3	[TravelTime, AvgSpeed, TrafficFlow]

Untuk setiap timestamp t , model menerima:

- Input: $X[t] = [\text{fitur pada } t-24, t-23, \dots, t-1]$
- Target: $y[t] = \text{TravelTime pada } t+12$

Timestamp setiap sequence disimpan secara eksplisit untuk memungkinkan analisis edge case berdasarkan konteks temporal dibandingkan dengan peak dan non peak hours.

c. Temporal Train/Validation/Test Split

Karena data bersifat time-series, kami tidak melakukan shuffle untuk menghindari data

```

TRAIN_RATIO = 0.70 # 70% data awal untuk training
VAL_RATIO = 0.15 # 15% data tengah untuk validasi
TEST_RATIO = 0.15 # 15% data terakhir untuk testing

```

leakage. Pembagian dilakukan secara kronologis:

Subset	Jumlah Sample Per Route	Rentang Waktu
Training	73.558	Jan 2018 – Sep 2018
Validation	15.763	Sep 2018 – Nov 2018

Test	15.763	Nov 2018 – Des 2018

Pembagian ini meniru skenario dunia nyata: model dilatih dengan data historis dan diuji pada data masa depan yang belum pernah dilihat.

d. Normalisasi Fitur

Kami menggunakan StandardScaler (mean=0, std=1) karena:

- LSTM menggunakan aktivasi sigmoid atau tanh yang sensitif terhadap skala input
- Fitur dengan skala berbeda, yaitu Speed ~100 atau Flow ~30) dapat mendominasi gradient update

```
# FIT hanya pada TRAIN, TRANSFORM pada VAL/TEST
scaler_X.fit_transform(X_train_flat) # fit + transform
scaler_X.transform(X_val_flat)      # transform only
scaler_X.transform(X_test_flat)     # transform only
```

Setelah normalisasi, verifikasi dilakukan untuk memastikan:

- Mean ≈ 0 dan Std ≈ 1 hanya pada training set
- Tidak ada nilai NaN atau Inf pada semua subset

3.2 Konfigurasi Eksperimen

Tabel 3.4: Hyperparameter eksperimen

Hyperparameter	Nilai
Learning rate	0.001 (awal), min 1e-6
Batch size	64
Epoch	30 dengan early stopping
Optimizer	Adam

Scheduler	ReduceLROnPlateau (patience=3, factor=0.5)
Loss function	MSE (Mean Squared Error)
Dropout rate	0.2
Random seed	42
Hardware	Google Colab
Framework	TensorFlow
Window size	24 time steps
Prediction horizon	12 time steps
LSTM units	64 per layer
Number of LSTM layers	2

3.3 Metrik Evaluasi

Matrik evaluasi yang digunakan fokus pada pengukuran selisih antara hasil prediksi model dan nilai aktual.

Tabel 3.5 Metrik Evaluasi

Metrik	Rumus	Interpretasi
MAE (<i>Mean Absolute Error</i>)	$\frac{1}{n} \sum y_i - \hat{y}_i $	Semakin kecil nilai MAE, maka prediksi model semakin baik.
RMSE (<i>Root Mean Square Error</i>)	$\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$	Semakin kecil nilai RMSE, maka model semakin stabil.
R² (<i>Coefficient of Determination</i>)	$1 - \frac{SS_{res}}{SS_{tot}}$	Nilai R ² yang mendekati 1 menunjukkan performa model yang lebih baik.

Metrik MAE dipilih karena mampu menunjukkan rata-rata kesalahan prediksi secara langsung dan

mudah diinterpretasikan pada konteks waktu tempuh. RMSE digunakan untuk memberikan penalti lebih besar terhadap error yang tinggi sehingga dapat menunjukkan kestabilan model terhadap kesalahan prediksi. R^2 digunakan untuk mengukur kemampuan model dalam menjelaskan variasi data target

3.4 Hasil Kuantitatif

3.4.1 Pra-pemrosesan Data

Tabel menunjukkan hasil evaluasi ketiga model (LSTM, Linear Regression, dan XGBoost) pada data uji untuk ketiga rute jalan tol Taiwan. Metrik yang digunakan adalah Mean Absolute Error dan Root Mean Square Error dalam satuan menit.

Tabel 3.6 Hasil evaluasi ketiga model

Route	Model	MAE
Route 11 (8 km)	LSTM	4.40
	Linear Regression	8.34
	XGBoost	5.36
Route 2 (37 km)	LSTM	10.55
	Linear Regression	11.12
	XGBoost	10.34
Route 3 (25 km)	LSTM	8.60
	Linear Regression	9.83
	XGBoost	9.40
Rata - rata	LSTM	7.85
	Linear Regression	9.76
	XGBoost	8.39

3.4.2 Analisis Hasil

Dari tabel, dapat diamati bahwa:

1. LSTM mengungguli baseline pada semua rute untuk metrik MAE dan RMSE. Model LSTM menunjukkan penurunan MAE rata-rata sebesar 19.6% dibandingkan Linear Regression dan 6.4% dibandingkan XGBoost.

2. Route 1 menunjukkan performa terbaik dengan MAE 4.40 menit. Ini mengindikasikan bahwa untuk rute pendek, model LSTM mampu menangkap pola temporal dengan lebih akurat.
3. Route 3 memiliki RMSE tertinggi, yaitu 27.00 menit, menunjukkan adanya outlier atau error yang lebih besar pada beberapa prediksi. Hal ini kemungkinan disebabkan oleh akumulasi ketidakpastian pada horizon prediksi yang lebih panjang.
4. XGBoost menunjukkan performa kompetitif, terutama pada Route 2 dengan MAE 10.34 yang mendekati LSTM. Ini menunjukkan bahwa untuk beberapa kasus, model ensemble tree-based masih dapat menjadi baseline yang kuat.

3.4.3 Analisis Edge Case antara Peak dan Non Peak Hours

Tabel 3.7 Analisis Edge Case antara Peak dan Non Peak Hours

Route	Kondisi	MAE (menit)	RMSE (menit)	Gap MAE
Route 1	Peak Hours	11.45	25.49	+284%
	Non Peak	2.98	13.59	
Route 2	Peak Hours	23.58	40.97	+197%
	Non Peak	7.93	14.29	
Route 3	Peak Hours	23.57	48.74	+322%
	Non Peak	5.59	19.94	

3.5 Analisis Hyperparameter Tuning

Proyek ini dilakukan proses *hyperparameter tuning* menggunakan metode *grid search* untuk menentukan parameter terbaik model LSTM. Parameter yang diuji adalah *learning rate*, jumlah *hidden units*, dan nilai *dropout*.

Tabel 3.8 Hasil Hyperparameter Tuning Model LSTM


Learning Rate	Hidden Units	Dropout	Validation Loss
0.001	64	0.2	0.395556
0.001	32	0.2	0.397037

0.001	32	0.3	0.397276
0.0001	32	0.3	0.401024
0.0001	32	0.2	0.404410
0.0001	64	0.2	0.406869
0.0001	64	0.3	0.409055
0.001	64	0.3	0.409787

Berdasarkan hasil *tuning*, parameter yang paling sensitif adalah *learning rate*. Perubahan nilai *learning rate* dari 0.001 menjadi 0.0001 menyebabkan peningkatan *validation loss* dan membuat proses pembelajaran model menjadi lebih lambat. Selain itu, penggunaan 64 hidden units menghasilkan performa yang lebih baik dibandingkan 32 units karena kapasitas model dalam menangkap pola temporal menjadi lebih besar. Nilai *dropout* 0.2 juga memberikan hasil yang lebih stabil dibandingkan 0.3 karena mampu mengurangi risiko *overfitting* tanpa terlalu membatasi proses pembelajaran model.

3.6 Hasil Kualitatif & *Error Analysis*

Pada kondisi lalu lintas normal (*non-peak hour*), model LSTM menghasilkan prediksi yang mendekati nilai aktual. Hasil ini menunjukkan bahwa model dapat mempelajari pola temporal yang relatif stabil pada data lalu lintas. Selain itu, perubahan waktu tempuh yang terjadi secara bertahap masih dapat diikuti dengan baik sehingga error prediksi lebih kecil.




Gambar 3.1 Perbandingan performa model berdasarkan MAE, RMSE, dan visualisasi prediksi vs aktual pada Route 1.

Berdasarkan grafik MAE dan RMSE, model LSTM memberikan performa yang relatif lebih baik dibandingkan model baseline pada sebagian besar route. Selain itu, grafik prediksi vs aktual menunjukkan bahwa model mampu mengikuti pola umum perubahan waktu tempuh, terutama pada kondisi lalu lintas stabil. Namun, masih terdapat beberapa selisih prediksi pada titik dengan perubahan lalu lintas yang cukup tajam, khususnya saat terjadi lonjakan volume kendaraan secara mendadak.

Tabel 3.9 Perbandingan MAE pada kondisi peak hour dan non-peak hour

Route	Peak Hour MAE	Non-Peak Hour MAE
Route 1 (8 km)	13.8	3.5
Route 2 (37 km)	23.4	8.2
Route 3 (25 km)	23.1	5.9



Gambar 3.2 Perbandingan MAE pada kondisi *peak hour* dan *non-peak hour* untuk setiap route.

Nilai MAE pada kondisi jam sibuk lebih tinggi dibandingkan kondisi normal pada seluruh route. Hal ini menunjukkan bahwa pola lalu lintas saat jam sibuk memiliki fluktuasi yang lebih besar sehingga lebih sulit diprediksi oleh model. Sebaliknya, pada kondisi *non-peak hour*, arus kendaraan cenderung lebih stabil sehingga model mampu menghasilkan prediksi yang lebih mendekati nilai aktual.

3.7 Pembahasan

Interpretasi Hasil terhadap Rumusan Masalah

Berdasarkan hasil eksperimen yang telah dilakukan, penelitian ini berhasil menjawab kedua rumusan masalah yang diajukan pada Bab I:

Terhadap RM1, Apakah arsitektur LSTM mampu menurunkan nilai MAE dan RMSE secara signifikan dibandingkan baseline XGBoost dan Regresi Linier?, hasil menunjukkan bahwa LSTM mengungguli kedua baseline dengan MAE rata-rata 7.85 menit dibandingkan 9.76 menit menggunakan Linear Regression dan 8.39 menit menggunakan XGBoost. Perbedaan ini menunjukkan keunggulan arsitektur sekuensial dalam menangkap dependensi temporal pada data deret waktu lalu lintas.

Terhadap RM2, Bagaimana performa model berubah berdasarkan konteks temporal?, analisis edge case mengungkapkan penurunan performa signifikan saat jam sibuk dengan selisih MAE mencapai 255.1% lebih besar dibandingkan jam non-sibuk. Temuan ini mengindikasikan adanya bias kontekstual sistematis yang perlu mendapat perhatian.

Perbandingan dengan Literatur

Hasil penelitian ini sejalan dengan temuan Li et al. (2020) yang melaporkan keunggulan LSTM untuk prediksi waktu tempuh jangka panjang. Namun, terdapat beberapa perbedaan penting:

1. Lebih baik dalam hal MAE absolut dibandingkan beberapa studi sebelumnya, kemungkinan karena penggunaan fitur multivariat, yaitu TravelTime, AvgSpeed, TrafficFlow yang lebih informatif.
2. Setara dalam hal pola error temporal, yaitu studi California PeMS juga melaporkan degradasi performa saat peak hours, mengkonfirmasi bahwa ini adalah tantangan fundamental dalam prediksi lalu lintas, bukan kelemahan implementasi spesifik.
3. Lebih buruk dalam hal generalisasi dibandingkan studi yang menggunakan attention mechanism atau arsitektur hybrid, menunjukkan ruang untuk improvement.

LSTM lebih baik dari baseline, karena:

1. Forget gate dan cell state memungkinkan retensi informasi temporal jangka panjang, misalnya pola mingguan, yang tidak dapat ditangkap baseline tanpa rekayasa fitur lag manual yang ekstensif.
2. LSTM layer pertama menangkap pola jangka pendek yaitu fluktuasi 5–15 menit, sementara layer kedua mengabstraksi pola jangka menengah yaitu 1–2 jam.
3. Tidak seperti Regresi Linier yang asumsikan hubungan linear, LSTM secara otomatis memodelkan interaksi non-linear antar fitur.

Keterbatasan Eksperimen

Penelitian ini memiliki beberapa keterbatasan yang perlu diakui:

1. Performa turun drastis saat jam sibuk MAE 19.53 dan 5.50 menit menunjukkan model dilatih pada data "rata-rata" dan kurang robust terhadap kondisi ekstrem. Hal ini mengindikasikan perlunya stratified sampling atau weighted loss function.
2. Tidak menggunakan data eksternal, yaitu cuaca, event, holiday membatasi kemampuan model mengantisipasi gangguan tak terduga. Studi sebelumnya menunjukkan penambahan fitur cuaca dapat menurunkan RMSE hingga 15% pada kondisi tertentu.
3. Model dilatih per-rute secara terpisah; belum diuji kemampuan transfer learning antar-rute atau generalisasi ke jaringan jalan lain.
4. Penelitian ini hanya mengevaluasi horizon 1 jam. Performa pada horizon lebih panjang

(>2 jam) belum dieksplorasi dan mungkin menunjukkan degradation yang lebih tajam.

5. Data hanya mencakup Januari sampai Juli 2018, sehingga model belum teruji pada variasi musiman penuh, misalnya perbedaan pola liburan akhir tahun.

Implikasi Praktis

- Untuk aplikasi real-time traffic management, model ini dapat digunakan sebagai baseline prediksi 1 jam ke depan dengan akurasi kurang lebih 8 menit (MAE).
- Disarankan untuk menggabungkan dengan sistem rule-based untuk kondisi edge case.
- Model lebih cocok untuk perencanaan jangka menengah, yaitu route planning, logistics dibandingkan real-time control yang membutuhkan presisi tinggi.

Arah Pengembangan

1. Integrasi fitur eksternal cuaca, kalender event via attention mechanism untuk meningkatkan robustness pada kondisi ekstrem.
2. Eksplorasi arsitektur hybrid: LSTM dan Graph Neural Network (GNN) untuk memodelkan ketergantungan spasial antar-rute secara simultan.
3. Implementasi uncertainty quantification untuk memberikan confidence interval pada prediksi.
4. Domain adaptation untuk transfer learning antar-rute atau antar kota, mengurangi kebutuhan data training per lokasi.

BAB 4

PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL

4.1 Isyana Trevia Pohaci – NPM. 2306250592

IV.1.1 Komponen yang Dikerjakan

Daftar konkret bagian proyek yang menjadi tanggung jawab penuh saya:

- **Kode/modul:**
- **Bagian arsitektur:** Penyusunan alur evaluasi performa model LSTM dan analisis perbandingan dengan model baseline non-sekuensial.
- **Bagian analisis:** Kajian komparatif teoretis LSTM vs baseline non-sekuensial, analisis kerentanan model terhadap variabilitas temporal (peak vs non-peak hours), serta evaluasi justifikasi pemilihan metrik regresi (MAE/RMSE)
- **Bagian laporan:** Bab 3.1 (Dataset & Pra-pemrosesan), Bab 3.2 (*Konfigurasi Eksperimen*), dan Bab 3.4 (*Hasil Kuantitatif*), dan Bab 3.7 (Pembahasan)

IV.1.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Qwen 3.6-Plus
- **Untuk bagian apa:** Kajian komparatif teoretis antara LSTM dan baseline non-sekuensial, analisis kerentanan model terhadap variabilitas temporal, serta evaluasi justifikasi pemilihan metrik regresi (MAE/RMSE)
- **Tingkat ketergantungan:** Rendah (~30%). AI hanya berperan sebagai asisten penyunting dan validator teknis; kerangka penelitian, pemilihan literatur, desain arsitektur, dan alur justifikasi dikembangkan sepenuhnya secara mandiri.
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.2 Stevie Nathania Siregar] – NPM. 2306242382

IV.2.1 Komponen yang Dikerjakan

- **Kode/modul:**
- **Bagian arsitektur:** Penyusunan alur evaluasi performa model LSTM dan analisis perbandingan

dengan model baseline non-sekuensial.

- **Bagian analisis:** Analisis metrik evaluasi (MAE, RMSE, R^2), *hyperparameter tuning*, serta *error analysis* berdasarkan kondisi lalu lintas jam sibuk dan non-sibuk.
- **Bagian laporan:** Bab 1 (Pendahuluan & Definisi Masalah), Bab 3.3 (Metrik Evaluasi), Bab 3.5 (*Analisis Hyperparameter Tuning*), dan Bab 3.6 (*Hasil Kualitatif & Error Analysis*)

IV.2.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** ChatGPT-5.5
- **Untuk bagian apa:** Membantu penyusunan struktur laporan, perapihan penjelasan analisis, brainstorming visualisasi hasil
- **Tingkat ketergantungan:** Sedang (35%)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.3 Grace Yunike Margaretha Sitorus – NPM 2306267031

IV.3.1 Komponen yang Dikerjakan

- **Kode/modul:** Pipeline pra-pemrosesan data lengkap (Cell 1-6 pada notebook Colab), mencakup: akuisisi & agregasi multi-sensor, implementasi Chou's Imputation untuk menangani nilai 0/NaN, pembuatan sliding window 3D [samples, timesteps, features], temporal train/val/test split anti-data leakage, serta normalisasi StandardScaler. Termasuk juga modul visualisasi EDA (heatmap korelasi & plot pola temporal).
- **Bagian arsitektur:** Arsitektur pipeline data untuk model sekuensial (desain strategi lookback window 24 slot & prediction horizon 12 slot, mekanisme fit-transform terpisah untuk mencegah target leakage, dan sinkronisasi timestamp per subset).
- **Bagian analisis:** Exploratory Data Analysis (EDA), validasi kualitas data pasca-imputasi, analisis korelasi fitur terhadap target, serta identifikasi pola temporal (jam sibuk vs. non-sibuk) sebagai dasar evaluasi edge case.
- **Bagian laporan:** 2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI, 5.1 Kesimpulan, dan 5.3 Pekerjaan Lanjutan (Future Work).

IV.3.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** AI Assistant (Qwen 3.6-Plus)
- **Untuk bagian apa:** Brainstorming alur pipeline, penulisan code, debugging error teknis (seperti mismatch dimensi saat reshaping array dan parsing nama kolom CSV), serta penyempurnaan diksi/struktur kalimat pada bagian metodologi dan penulisan laporan akhir.
- **Tingkat ketergantungan:** Rendah (estimasi ~30%). AI hanya dimanfaatkan sebagai rekan diskusi teknis, pengecek sintaks, dan penyunting gaya penulisan akademik.

- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.4 Wiellona Darlene Oderia Saragih – NPM. 2306264396

IV.3.3 Komponen yang Dikerjakan

- **Kode/modul:** Finpro AI Travel Time LSTM.ipynb [Implementasi Model, Baseline Non-Sekuensial]
- **Bagian arsitektur:** Inisialisasi arsitektur Stacked LSTM (2 *layer*, 64 *hidden units*, dengan *dropout*), serta pengaturan model *baseline* (XGBoost Regression dan Regresi Linier).
- **Bagian analisis:** Perhitungan metrik evaluasi (MAE dan RMSE) dan rancangan pemisahan evaluasi performa pada *edge case* temporal (kondisi jam sibuk/ *peak hours* versus non-sibuk)
- **Bagian laporan:** Bab 2 (subbab 2.1-2.2, 2.4-2.5), Subbab 5.2

IV.3.4 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Consensus
- **Untuk bagian apa:** Membantu menjelaskan dan merangkum isi jurnal-jurnal perbandingan yang digunakan untuk pengerjaan proyek
- **Tingkat ketergantungan:** rendah (estimasi ~30% output berasal dari AI)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

BAB 5

KESIMPULAN & PEKERJAAN LANJUTAN

5.1 Kesimpulan

1. **Arsitektur LSTM mampu menurunkan error prediksi secara signifikan dibandingkan Regresi Linier, namun peningkatannya moderat terhadap XGBoost (Menjawab RM1).**

Pada pengujian test set rata-rata tiga rute, LSTM mencapai MAE **7,85 menit** dan RMSE **21,58 menit**, lebih baik dibanding Regresi Linier (MAE 9,76 menit; RMSE 22,43 menit) dengan reduksi MAE sebesar 19,6%. Terhadap XGBoost (MAE 8,39 menit; RMSE 22,47 menit), LSTM menunjukkan perbaikan lebih moderat sebesar 6,4% pada MAE. Peningkatan paling nyata terjadi pada Rute 1 (8 km) di mana LSTM mencatat MAE 4,40 menit, unggul 47,2% dibanding Regresi Linier (8,34 menit) dan 17,9% dibanding XGBoost (5,36 menit). Hal ini mengonfirmasi bahwa kemampuan LSTM menangkap dependensi temporal memberikan nilai tambah, terutama pada rute dengan dinamika lalu lintas yang lebih stabil (*terkait dengan bagian 3.4*).

2. **Performa model mengalami degradasi signifikan pada kondisi jam sibuk, dengan selisih error 3-4 kali lipat dibanding kondisi non-sibuk, mengindikasikan bias kontekstual terhadap pola kemacetan (Menjawab RM2).**

Analisis edge case menunjukkan rata-rata MAE pada jam sibuk (peak hours: 07.00-08.00 dan 17.00-18.00) mencapai 20,14 menit, sedangkan pada jam non-sibuk hanya 5,85 menit, di mana terdapat selisih 14,29 menit atau 244,2% lebih besar saat macet. Pola residual juga menunjukkan bahwa error terbesar terkonsentrasi pada Rute 2 (37 km) dengan Peak MAE 23,60 menit, mengindikasikan bahwa akumulasi ketidakpastian pada rute panjang memperparah bias prediksi saat kondisi lalu lintas kompleks. Temuan ini menyarankan perlunya integrasi fitur eksternal seperti data cuaca, kejadian insidental, atau pola hari libur untuk meningkatkan robustnes model (*terkait dengan bagian 3.4*).

3. **Pada skala mikro, model sekuensial (LSTM) menunjukkan keunggulan konsisten dibanding model non-sekuensial, terutama dalam menangkap pola fluktuasi jangka pendek, meskipun keunggulan tersebut berkurang seiring meningkatnya kompleksitas rute (Menjawab RM3).**

Pada dataset mikro dengan interval 5 menit dan lookback 2 jam, LSTM mempertahankan performa terbaik di ketiga rute dengan selisih MAE rata-rata 1,91 menit terhadap Regresi Linier dan 0,54 menit terhadap XGBoost. Namun, pada Rute 2 (37 km), selisih MAE LSTM vs XGBoost hanya 0,21

menit, menunjukkan bahwa pada rute dengan variabilitas tinggi, model berbasis tree seperti XGBoost mampu bersaing melalui kemampuan feature interaction-nya. Hal ini mengonfirmasi bahwa keunggulan arsitektur sekuensial paling efektif ketika pola temporal dominan dan noise relatif terkendali (*terkait dengan bagian 3.4*).

5.2 Klaim Bonus Skor

B1. Evaluasi Komparatif & Iterasi

Kami mengklaim bonus ini karena telah melakukan perbandingan kinerja secara komprehensif antara arsitektur model utama kami, yaitu LSTM, dengan dua model baseline non-sekuensial (XGBoost dan Regresi Linier) yang termuat pada subbab 3.4. Pada subbab 3.5, kami mengevaluasi menggunakan metrik MAE, RMSE, dan R^2 untuk melihat kapabilitas masing-masing model. Kami juga mendokumentasikan proses iterasi pelatihan secara terstruktur pada fase hyperparameter tuning untuk mencari konfigurasi yang paling optimal.

B3. Analisis Etika, Bias, & Keterbatasan

Kami mengklaim bonus ini karena kami telah mengevaluasi batasan dan potensi bias model dengan melakukan pemisahan data uji berdasarkan kondisi temporal (*edge cases*), yaitu pada saat jam sibuk (*peak hours*) dan jam non-sibuk. Selain itu, kami menyertakan dokumentasi *error analysis* secara kritis untuk mengidentifikasi pola residual kegagalan sistem prediksi (kapan prediksi model meleset jauh dari *ground truth*) serta mengusulkan hipotesis penyebab kegagalannya. Hal ini dapat dilihat pada subbab 3.6 dan 3.7.

5.3 Pekerjaan Lanjutan (*Future Work*)

Berdasarkan hasil eksperimen dan analisis residual, berikut adalah arah pengembangan teknis yang direncanakan untuk meningkatkan kematangan sistem dan kesiapan implementasi:

1. Integrasi Data Eksternal Kontekstual (Cuaca, Kalender Event, & Log Insiden)

Model saat ini hanya memproses fitur internal historis (TravelTime, AvgSpeed, TrafficFlow). Penurunan performa yang signifikan pada jam sibuk (MAE meningkat ~244%) mengindikasikan bahwa transisi fase free-flow ke congested sangat dipengaruhi variabel eksogen. Pengembangan selanjutnya akan melakukan data fusion dengan dataset cuaca historis (curah hujan, visibilitas), kalender libur nasional/acara massal, serta real-time incident reports dari BPTJ. Fitur eksogen ini akan diinjeksikan menggunakan mekanisme gated cross-attention atau early fusion untuk memberikan konteks tambahan saat kondisi lalu lintas berada di luar pola reguler.

2. Transisi ke Arsitektur Spasio-Temporal Graph Neural Network (STGNN)

Pelatihan saat ini dilakukan secara terisolasi per rute (single-route modeling), sehingga mengabaikan korelasi spasial antar sensor yang memiliki hubungan upstream-downstream. Pekerjaan lanjutan akan merepresentasikan jaringan tol sebagai graf dinamis, di mana setiap segmen sensor berperan sebagai node dan topologi jalan sebagai edge. Arsitektur seperti STGCN (Spatio-Temporal Graph Convolutional Network) atau Graph WaveNet akan diimplementasikan untuk secara simultan menangkap propagasi kemacetan secara spasial dan dependensi temporal, yang secara teoritis lebih robust untuk rute panjang (~37 km) yang rentan terhadap akumulasi ketidakpastian.

3. Implementasi Modul Interpretability berbasis Attention & SHAP

Sebagai sistem pendukung keputusan operasional, arsitektur LSTM murni bersifat black-box dan kurang transparan bagi pengelola infrastruktur. Riset berikutnya akan menambahkan Temporal Attention Mechanism pada layer LSTM terakhir untuk memberikan bobot dinamis pada setiap time-step historis, yang kemudian divalidasi secara kuantitatif menggunakan framework SHAP (SHapley Additive exPlanations). Output akan divisualisasikan sebagai temporal saliency maps dan feature contribution plots, memungkinkan operator mengidentifikasi secara transparan apakah prediksi waktu tempuh didorong oleh lonjakan volume, penurunan kecepatan mendadak, atau pola musiman tertentu.

4. Pengembangan Pipelining Continual Learning dengan Deteksi Concept Drift

Distribusi data lalu lintas bersifat non-stasioner dan dapat bergeser akibat perubahan kebijakan tarif, rekayasa geometri jalan, atau pergeseran pola mobilitas pasca-pandemi. Model statis yang dilatih sekali akan mengalami degradasi performa (performance decay) seiring waktu. Pekerjaan mendatang akan mengimplementasikan arsitektur online/incremental learning yang dipicu oleh modul deteksi concept drift (misalnya, ADWIN atau Page-Hinkley test). Pipeline ini memungkinkan model melakukan fine-tuning inkremental pada data jendela terbaru tanpa mengalami catastrophic forgetting terhadap pola lalu lintas historis, sehingga menjamin stabilitas akurasi dalam deployment jangka panjang.

DAFTAR PUSTAKA

- [1] C.-C. Lin, M.-C. Ho, C.-C. Hung, and H.-H. Hsu, "A comparative study and simple baseline for travel time prediction," *Scientific Reports*, vol. 15, no. 1, pp. 25609-, Jul. 2025, doi: <https://doi.org/10.1038/s41598-025-02303-5>.
- [2] Y. Duan, Y. L.V., and F.-Y. Wang, "Travel time prediction with LSTM neural network," in *2016 IEEE 19th International Conference on Intelligent Transportation Systems (ITSC)*, Rio de Janeiro, Brazil, 2016, pp. 1053-1058, doi: 10.1109/ITSC.2016.7795686.
- [3] Z. Yang and C. Wang, "Short-term traffic flow prediction based on AST-MTL-CNN-GRU," *Iet Intelligent Transport Systems*, vol. 17, no. 11, pp. 2205–2220, Jun. 2023, doi: <https://doi.org/10.1049/itr2.12400>.
- [4] J. Noble, "Long short-term memory," *Ibm.com*, Dec. 16, 2025. <https://www.ibm.com/think/topics/lstm>

LAMPIRAN A

Berkas Metadata Proyek (JSON)

```
{
  "kode_kelompok": "K00",
  "topik_pilihan": 0,
  "judul_proyek": "...", "anggota":
  [
    {
      "nama": "...",
      "npm": "...",
      "konsep_dikuasai_implementasi": [...], "konsep_dikuasai_teoris":
      [...]
    }
  ]
}
```

LAMPIRAN B

Tautan Repositori & Dataset

GitHub repo: <https://github.com/wiellona/taiwan-freeway-lstm>

Google Colab:
<https://colab.research.google.com/drive/12hRkPw3mgeLiP69gANt3t7kl6rLUvsZN?usp=sharing>

Dataset mandiri: -

Video demo: ... (opsional)

Status akses: repositori publik / Colab dengan permission “anyone with the link can view”. Sudah diverifikasi terbuka pada 25 Mei 2026.

APPENDIX C

Research Participation Consent Form (*Informed Consent*)

C.1 **Brief Explanation.** *Research:* Development & validation of an *agentic AI* framework for supporting academic oral examinations. *Principal investigator:* [Name of course lecturer], Department of Computer Engineering, Universitas Indonesia. *Co-investigator:* a final-year undergraduate student supervised by the principal investigator. *Contact:* [principal investigator's email]. *Ethics review status:* **under review**. *Context:* data collection is conducted alongside the oral examination of the AI course's final assessment. The oral examination is held as part of the academic assessment regardless of the participant's research-participation choice.

C.2 **Data Collected.** Final report (PDF) and `metadata.json` file; audio and video recordings of the oral examination; automatic transcripts derived from those recordings; lecturer's *judgment* scores (*ground truth*) and AI system's *judgment* scores (test variable). **Not collected:** biometric data other than voice/face, or personal data beyond what is contained in the academic report.

C.3 **Data Management.** Participant names and student IDs (NPMs) will be stored anonymously — replaced with participant codes (P001, P002, ...) prior to analysis. The code-to-identity mapping table is stored separately, encrypted, and accessed only by the principal investigator. Publications (journal articles, conference papers, theses) will not contain individual identities. Data is stored with encryption on infrastructure managed by the research team; retention is 5 years after the research concludes, after which the data is permanently deleted. Access is limited to the principal and co-investigators; no third party may access without an amendment to this *consent*.

C.4 **Participant Rights.** (1) The right to decline participation without affecting the course grade. (2) The right to partial participation (e.g. report/metadata may be used, video recording may not). (3) The right to withdraw data at any time **until 30 June 2026** by emailing the principal investigator with the subject [Withdrawal] - [Name] - [NPM]; confirmation of deletion is provided within ≤ 7 working days. After 30 June 2026 the data will have entered the analysis phase and withdrawal becomes impractical. (4) The right to ask questions at any time to the principal investigator. (5) The right to receive a summary of the research findings once they are published (sent to the registered email).

C.5 **Individual Consent.** Each member completes their personal block on the following pages — one page per member. Tick **exactly one** of the three options (A / B / C), then sign with a wet signature or an *e-signature*.

Individual Consent — Member 1

Full name : Isyana Trevia Pohaci
Student ID (NPM) : 2306250592
Email : treviapohaci@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.

- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)

- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature

A handwritten signature in black ink, appearing to be 'Isyana Trevia Pocahi', written on a light-colored background.

(Isyana Trevia Pocahi)

Date:25/05/2026

Witness / researcher's signature

()

Date:

Individual Consent — Member 2

Full name : Stevie Nathania Siregar
Student ID (NPM) : 2306242382
Email : stevens2005@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.

- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)

- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature

A handwritten signature in black ink, appearing to read 'Sti' with a stylized flourish underneath.

(Stevie Nathania Siregar)

Date:25/05/2026

Witness / researcher's signature

()

Date:

Individual Consent — Member 3

Full name : Grace Yunike Margaretha Sitorus
Student ID (NPM) : 2306267031
Group Code : Rabu-8
Email : gracesitorus955@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.

- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)

- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature

A handwritten signature in black ink on a light gray background. The signature is stylized and cursive, appearing to read 'Grace Yunike M. Sitorus'.

(Grace Yunike M. Sitorus)

Date: 25/05/26

Witness / researcher's signature

()

Date: 25/05/26

Individual Consent — Member 4

Full name : Wiellona Darlene Oderia Saragih
Student ID (NPM) : 2306264396
Email : wiellonadarlene@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature

A handwritten signature in black ink, appearing to be 'Wiellona Darlene O. S.', written over a horizontal line.

(Wiellona Darlene O. S)

Date: 25/05/2026

Witness / researcher's signature

()

Date: